

**SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA OSIJEK**

DIPLOMSKI STUDIJ

1. godina

**PROCJENA POZE ČOVJEKA U STVARNOM
VREMENU I PODUDARANJE SILUETA**

PROJEKTNI ZADATAK

Robotski vid

Patrik Jurić, Ivan Lubina, Fran Rumbak, Karlo Vlašić

Osijek, 2026

1. UVOD	1
2. MODEL	2
3. OZNAKE.....	3
4. IGRA.....	7
5. KORISNIČKO SUČELJE I BODOVANJE	8
6. ZAKLJUČAK	11

1. UVOD

U suvremenom računalnom vidu, prepoznavanje i analiza pokreta jedan je od čestih izazova, a pogotovo procjena poze čovjeka u stvarnom vremenu. Takva tehnologija omogućuje računalnim sustavima razumijevanje ljudskog tijela i položaj istog u prostoru. Česta primjena ove tehnologije se može vidjeti u biometriji, sigurnosnim sustavima, autonomnim vozilima, sportske medicine, fizikalne terapije te naprednih sučelja u industriji zabave.

Projektom se želi postići edukativna primjena prijašnje spomenute tehnologije. Često se tehnologija iza filtra za promjenu ili dodavanje elemenata na videozapisu ne vidi, ali koristi vrlo često, a upravo tehnologija koja prati pokrete ljudskog tijela može primijeniti u tom smislu. Iako cilj ovog projekt nije korištenje filtera, i dalje se u stvarnom vremenu procjenjuje pozu koja se dalje koristi za ocjenu točnosti.


Ciljevi ovog projekta je razviti interaktivni računalni sustav za praćenje i analizu motoričkih sposobnosti čovjeka kroz igru u stvarnom vremenu. Potpuna realizacija projekta može se provesti u tri ključna dijela. Prvi dio projekta je izrada alata za ručno označivanje referentnih anatomskih točaka na slikama silueta životinja. Drugi dio je Implementacija sustava za praćenje skeleta čovjeka u stvarnom vremenu preko web kamere pomoću MediaPipe okvira. Te posljednji dio može se svesti na razvoj upravljačke logike igre koja u realnom vremenu računa geometrijsko podudaranje i upravlja stanjima sustava (unos imena, prikaz rezultata i ljestvica najboljih rezultata).

Napokon posljednji dio sustava je evaluacija točnosti postavljanja poza, uspješnost praćenja zglobova u ovisnosti o osvjetljenju te brzina odziva algoritma.

U sljedećim poglavljima može se pronaći više o modelu, oznakama, igri te korisničkom sučelju i bodovanju.

2. MODEL

Korišten model za potrebe ovog projekta je *Pose Landmarker Lite*, koji može biti preuzet s udaljenog poslužitelja te je upravo na taj način korišten u skripti koja testira prikaz kostura, a i za daljnje korištenje u igri. Kao što se vidi na slici 2.1., model iscertava kostur uz identificirane ključne točke.




Slika 2.1., prozor koji se otvori nakon pokretanja skripte za testiranje kostura

Pose Landmarker Lite dio je *MediaPipe* rješenja koji je razvijen od *Googlea*, a on je napredan model dubokog učenja namijenjen za detekciju ljudskih poza tj. *pose estimation*, verzija korištena u projektu je *Lite* kako bi se ograničilo korištenje resursa. Model funkcionira na način gdje unutar prijenosa videa identificira 33 ključne točke ljudskog tijela, gdje je svaka točka opisana koordinatama i vrijednosti vidljivosti.


3. OZNAKE

Kako bi se ubrzao proces označivanja referentnih anatomskih točaka, izradio se alat kojim se mogu označiti anatomske točke, a alat određuje x i y udaljenosti s obzirom na ishodište odabrane fotografije. Alat, *annotate.py*, korišten je u te svrhe, a nakon pokretanju alata, može se, na slici 3.1., vidjeti rezultat pokretanja, gdje se korisniku daje uputa za određivanje referentne anatomske točke.



Slika 3.1., prozor koji se otvori nakon pokretanja skripte annotate.py


Kao prva anatomska struktura odabran je nos, a nakon nje slijede ostale strukture poput ramena, zapešća, gležnja... Nastavak odabiranja je prikazan na slici 3.2., gdje se, također, vidi i prikaz označene točke.



Slika 3.2., prozor koji se ažurirao nakon odabiranja pripadne referentne anatomske točke

Uz mogućnosti odabiranja i prikaza referentnih točaka, skripta ima mogućnost poništiti prijašnje odabranu točku, pohraniti odabir i izaći iz alata, uz pomoć pritiska tipki u, s ili esc na tipkovnici.

Nakon dovoljno zadovoljivih točaka na fotografijama, čiji se primjer može vidjeti na slici 3.3., i spremanje istih, alat sprema informaciju na način gdje se x i y udaljenosti od gornjeg lijevog kuta fotografije povećavaju, tako da se udaljenost x osi povećava približavanjem desnog kuta fotografije, odnosno, u slučaju s osi y, povećava s približavanjem donjem lijevom kutu fotografije. Vrijednosti udaljenosti su u rasponu 0.0 i 1.0.



Slika 3.3., prozor nakon odabiranja svih referentnih anatomskih točaka

Pritiskom tipke s na tipkovnici, podatci se spremaju u *json* formatu, a primjer spremljenih podataka može se pronaći u tablici 3.1. Podatci su spremljeni kao istoimena fotografija, samo u *json* formatu i u *annotations* direktoriju.

Tablica 3.1., primjer izgleda dijela referentne anatomske točke spremljenog u *json* formatu

"image": "images/bug.png",
"landmarks": {
"0": {
"x": 0.5309278350515464,
"y": 0.33771106941838647,
"name": "Nose"
},

4. IGRA

Nakon što su izrađene referentne oznake anatomskih točaka pomoću alata *annotate.py* te je odabran model za praćenje ljudskog skeleta u stvarnom vremenu, slijedi objedinjavanje tih komponenti unutar glavne skripte *pose_game.py*, koja predstavlja upravljačku logiku same igre. Skripta povezuje web kameru, MediaPipe model i spremljene anotacije u jedinstven interaktivni tijek igre podijeljen u runde.

Pokretanje igre vrši se iz terminala naredbom *python pose_game.py <argument>*, pri čemu argument može biti pojedinačna *json* datoteka s anotacijama, naziv direktorija (primjerice *annotations*) iz kojeg se učitavaju sve pronađene datoteke oznaka, ili datoteka poput *playlist.json*, koja sadrži popis naziva pojedinih anotacija te time određuje redoslijed razina igre. Ako korisnik ne navede argument, sustav automatski učitava zadanu datoteku *playlist.json*. Dodatno, korisnik parametrom *--name* može unaprijed odrediti ime igrača, čime se preskače naknadni unos imena unutar grafičkog sučelja.


Za svaku učitanoj anotacijskoj datoteku igra pokreće zasebnu rundu. Fotografija životinje pridružena toj anotaciji učitava se iz direktorija *images* te se prilagođava rezoluciji web kamere kako bi poslužila kao pozadina prozora igre. Referentne anatomske točke iz anotacije prikazuju se kao žuti krugovi s pripadajućim nazivima, dok se istovremeno, iz podataka dobivenih MediaPipe modelom, u stvarnom vremenu iscrtava korisnikov kostur. Kostur se sastoji od 33 ključne točke povezane unaprijed definiranim parovima susjednih zglobova (*POSE_CONNECTIONS*), čime se dobiva vizualni prikaz cijelog tijela igrača, a ne samo pojedinačnih točaka koje se boduju.

Svaka runda traje unaprijed određeno vrijeme, definirano konstantom *ROUND_DURATION* (30 sekundi), tijekom kojeg sustav u svakom prikazanom okviru računa broj trenutno pogođenih zglobova te pamti najveći postignuti broj tijekom cijele runde. Način na koji se određuje podudaranje pojedinog zgloba, kao i konačni izračun bodova na temelju najboljeg postignutog rezultata, detaljnije je opisan u sljedećem poglavlju.

Po isteku vremena runde, sustav kratko prikazuje rezultat te se, nakon stanke od tri sekunde, automatski prelazi na sljedeću fotografiju odnosno sljedeću rundu, sve dok se ne obrade sve anotacijske datoteke iz odabranog popisa. Tijekom cijele igre, u bilo kojem trenutku, igrač pritiskom tipke *q* može prekinuti igru i izaći iz aplikacije.


5. KORISNIČKO SUČELJE I BODOVANJE

Prije samog početka igre, unutar istog OpenCV grafičkog sučelja (Pose Game) prikazanog na slici 5.1., sustav od korisnika zahtijeva unos imena. Unos se vrši direktno preko tipkovnice s vizualnim prikazom unesenih znakova i treperećeg pokazivača u stvarnom vremenu, čime je izbjegnuto korištenje standardnog terminala.



Slika 5.1., prikazani prozor za unos imena korisnika prije samog početka igre

Tijekom trajanja runde, igrač pokušava tijelom imitirati pozu sa slike u pozadini. Sustav u stvarnom vremenu (30Hz) računa Euklidsku udaljenost između korisnikovih zglobova i anotiranih točaka. Ako je udaljenost manja od praga *MATCH_THRESHOLD* (0.12), krug postaje zelen. Gornji desni kut prikazuje preostalo vrijeme runde, a donji dio HUD-a trenutni i najbolji broj pogođenih zglobova, kao što se može vidjeti na slici 5.2.




Slika 5.2., prikazani prozor tijekom igranja igre



Slika 5.3., prikazani prozor za kraj igre s prikazanim rezultatima

Nakon isteka vremena prikazuje se prozor kao na slici 5.3., na kojem se mogu vidjeti rezultati runde, ukupan rezultat i druge informacije o uspjehu igrača.

Napokon, nakon što je igrač prošao kroz sve slike iz *playlist.json*, sustav generira konačnu ljestvicu najboljih rezultata (*LEADERBOARD*) učitavanjem podataka iz *highscores.json*. Trenutni igrač i njegov ostvareni rezultat dinamički su istaknuti žutom bojom radi lakše uočljivosti unutar generirane tablice, kao što je prikazano na slici 5.4.



Slika 5.4., prikazani prozor s pet najboljih rezultata

6. ZAKLJUČAK

U ovom projektu uspješno je proveden razvoj i implementacija interaktivnog računalnog sustava za procjenu poze čovjeka u stvarnom vremenu i interaktivno podudaranje sa siluetama. Kombinacijom Google MediaPipe okvira i BlazePose arhitekture neuronske mreže ostvareno je iznimno brzo i robusno praćenje anatomskih točaka tijela bez potrebe za specijaliziranim dubinskim (RGB-D) kamerama, već korištenjem standardne monokularne web kamere.

Korištenjem Euklidske udaljenosti i normaliziranih koordinata unutar JSON struktura, sustav je uspješno riješio problem neovisnosti o rezoluciji prikaza i udaljenosti igrača od kamere. Razvijeno rješenje za unos imena i prikaz ljestvice najboljih rezultata unutar jedinstvenog OpenCV prozora pruža zaokruženo i fluidno korisničko iskustvo. Rezultati testiranja potvrđuju visoku točnost algoritama dubokog učenja te dokazuju njihovu primjenjivost u suvremenim sustavima računalnog vida za analizu ljudskog pokreta, fizikalnu rehabilitaciju i gamifikaciju.

LITERATURA

OpenCV Team, "OpenCV-Python," PyPI, 2026. [Online]. Dostupno na: <https://pypi.org/project/opencv-python/>. [Pristupljeno: 2. srpnja 2026.].

Google, "MediaPipe," PyPI, 2026. [Online]. Dostupno na: <https://pypi.org/project/mediapipe/>. [Pristupljeno: 2. srpnja 2026.].

Google Developers, "Pose Landmarker," MediaPipe Solutions, 2026. [Online]. Dostupno na: https://developers.google.com/edge/mediapipe/solutions/vision/pose_landmarker. [Pristupljeno: 2. srpnja 2026.].

NumPy Developers, "NumPy," NumPy, 2026. [Online]. Dostupno na: <https://numpy.org/>. [Pristupljeno: 2. srpnja 2026.].

Python Software Foundation, "time — Time access and conversions," Python 3.12.4 documentation, 2026. [Online]. Dostupno na: <https://docs.python.org/3/library/time.html>. [Pristupljeno: 2. srpnja 2026.].

Python Software Foundation, "math — Mathematical functions," Python 3.12.4 documentation, 2026. [Online]. Dostupno na: <https://docs.python.org/3/library/math.html>. [Pristupljeno: 2. srpnja 2026.].